

Informe Técnico:

Análisis de Base de datos

Caso Proyecto [AgroIntelligence]

Integrantes: Matias Bustos

Allan Salinas

Fernando Carter

Sede: Maipú

Sección: 001D

Docente: Viviana Poblete Lopez

a. Resumen ejecutivo.....	3
b. Justificación del modelo utilizado.....	3
c. Pruebas y/o experimentos realizados.....	4
d. Resultados y comparaciones.....	6
e. Optimización aplicada.....	7
f. Conclusiones.....	8

a. Resumen ejecutivo

Se entrenó un modelo de árbol de decisión para clasificar la calidad del fruto en tres categorías (`Desecho`, `Exportación`, `Local`). El árbol base se limitó a una profundidad controlada (`max_depth=3`) para priorizar interpretabilidad y reducir sobreajuste. Las métricas observadas muestran un desempeño global moderadamente bajo (`accuracy` $\approx$ 36.7%, `F1` ponderada $\approx$ 0.27) y un patrón de confusión: el modelo tiende a predecir `Local` para la mayoría de casos, no detectando `Desecho` y confundiendo `Exportación` con `Local`.

Se aplicó optimización por hiperparámetros comparando `GridSearchCV` y `RandomizedSearchCV`. Las mejoras en CV y en test fueron marginales, por lo que se recomienda completar trabajo adicional en balanceo de clases, feature engineering y probar modelos ensemble antes de depender del árbol como solución final.

Finalmente implementamos el algoritmo K-Means con el objetivo de identificar agrupaciones dentro del conjunto de datos agrícolas considerando variables relacionadas con características del suelo, nutrientes y producción. Para mejorar el comportamiento del modelo se aplicó un proceso de escalado utilizando `StandardScaler`, permitiendo que todas las variables participaran con la misma importancia durante el entrenamiento.

También se realizaron distintas pruebas y comparaciones entre modelos con y sin escalado, evaluando el efecto del preprocesamiento sobre los resultados obtenidos, para terminar aplicando métodos de optimización y evaluación para analizar la calidad de los grupos generados.

b. Justificación del modelo utilizado

El árbol de decisión fue elegido por su interpretabilidad: permite visualizar qué variables y umbrales determinan las predicciones, lo cual es valioso para usuarios agrícolas que necesitan explicaciones claras. Además, un árbol poco profundo facilita la comunicación de reglas sencillas (p. ej. si `nitrógeno` $\leq$ X entonces ...).

Limitando la profundidad se reduce el riesgo de memorizar datos y se mejora la capacidad de explicar decisiones; sin embargo, esto puede degradar la capacidad de capturar fronteras complejas entre clases. Por eso el árbol se usó como modelo inicial y de referencia interpretativa.

El modelo K-Means fue seleccionado debido a que corresponde a un método de aprendizaje no supervisado que permite identificar patrones y similitudes entre observaciones sin utilizar una variable objetivo durante el entrenamiento.

Su aplicación permitió realizar un análisis exploratorio de los datos agrícolas con el propósito de identificar posibles agrupaciones naturales considerando las características disponibles en el conjunto de datos.

A diferencia de los modelos supervisados utilizados, K-Means no busca predecir categorías específicas, sino agrupar registros según características similares.

c. Pruebas y/o experimentos realizados

Entrenamiento del árbol base con `max_depth=3` y evaluación en split train/test estratificado (`test_size=0.2`).

Cálculo de métricas: accuracy, matriz de confusión, reporte de clasificación (precision/recall/f1 por clase).

Visualización del árbol (`plot_tree`) mostrando las primeras 3 profundidades para facilitar interpretación.

Optimización de hiperparámetros: comparación entre `GridSearchCV` y `RandomizedSearchCV` sobre parámetros como `criterion`, `min_samples_split`, `min_samples_leaf` y `max_features`. La búsqueda se realizó con validación cruzada (`cv=5`) y scoring por `accuracy` en la implementación actual.

Guardado de modelos con `joblib` para reproducibilidad: `models/arbol_decision.pkl` (base) y `models/arbol_decision_optimizado.pkl` (mejor encontrado).

Modelo Kmeans: Durante el desarrollo del modelo se realizaron diferentes pruebas con el objetivo de evaluar su comportamiento y mejorar los resultados obtenidos.

Las pruebas realizadas fueron:

- Entrenamiento de un modelo sin aplicar escalado.
- Entrenamiento de un modelo utilizando `StandardScaler`.
- Comparación entre ambos modelos para analizar cambios en la asignación de clusters.
- Aplicación del método del codo para identificar posibles valores adecuados de K.
- Evaluación mediante el coeficiente Silhouette para determinar la calidad de agrupamiento.
- Comparación entre los grupos generados y la variable `target_calidad`.

Estas pruebas permitieron observar el comportamiento del algoritmo y analizar el impacto que poseen las distintas etapas del preprocesamiento sobre el modelo final.

d. Resultados y comparaciones

Arbol-decisiones:

Métricas principales (test):

- Accuracy $\approx 36.67\%$
- F1 ponderada ≈ 0.27

Matriz de confusión: tendencia a predecir `Local`; `Desecho` no es detectada (recall = 0), `Exportación` se confunde con `Local` frecuentemente.

Comparación Grid vs Randomized (resumen):

- GridSearchCV — CV best_score ≈ 0.350 , accuracy en test ≈ 0.379 .
- RandomizedSearchCV — CV best_score ≈ 0.356 , accuracy en test ≈ 0.371 .

Interpretación: RandomizedSearch obtuvo mejor score en CV pero GridSearch dio ligeramente mejor accuracy en test; las diferencias son pequeñas y no resuelven el problema de fondo.

En conjunto, el árbol identifica variables importantes (por ejemplo `nitrogeno`, `humedad\_suelo`, `radiacion\_solar`) pero las fronteras entre clases son difusas, lo que limita la precisión en clases minoritarias.

K-Means:

Para evaluar el desempeño del modelo se analizaron los grupos generados por K-Means y posteriormente se compararon con la variable target_calidad, la cual contiene las categorías Desecho, Exportación y Local.

Se compararon los clusters generados con la variable target_calidad. Los resultados muestran una distribución relativamente uniforme entre las categorías Desecho, Exportación y Local dentro de cada grupo generado.

La comparación realizada mostró el siguiente comportamiento:

- Cluster 0 → mezcla de registros Desecho, Exportación y Local.
- Cluster 1 → mezcla de registros Desecho, Exportación y Local.
- Cluster 2 → mezcla de registros Desecho, Exportación y Local.

Esto indica que el algoritmo K-Means no logró identificar agrupaciones que representen claramente la calidad del producto.

También se realizó una comparación entre el modelo sin escalado y el modelo escalado. Los resultados mostraron cambios en la asignación de registros a los grupos encontrados, evidenciando que el proceso de normalización influye directamente en el comportamiento del algoritmo. Esto ocurre debido a que K-Means utiliza medidas de distancia y variables con escalas mayores pueden dominar el proceso de agrupamiento.

En esta etapa también se asignaron etiquetas descriptivas (Grupo Agrícola A, Grupo Agrícola B y Grupo Agrícola C) con el objetivo de facilitar la interpretación y análisis de los grupos generados.

e. Optimización aplicada

Se definieron grillas y distribuciones para los hiperparámetros del `DecisionTreeClassifier`: `'criterion'`, `'max_depth'` (respetando la restricción de profundidad baja), `'min_samples_split'`, `'min_samples_leaf'` y `'max_features'`.

Se ejecutó `'GridSearchCV'` (exploración exhaustiva de la grilla) y `'RandomizedSearchCV'` (muestras aleatorias) con `'cv=5'` y `'scoring='accuracy''` en la configuración actual. Se eligió el mejor estimador entre ambas búsquedas según el `'best_score_'` y se evaluó en la partición de prueba.

Resultado: pequeñas mejoras en validación cruzada y test, sin cambio sustancial en la detección de clases minoritarias. Por ello se recomienda en futuros pasos cambiar el `'scoring'` a `'f1_macro'` y aplicar remuestreo/ponderación de clases para priorizar el rendimiento por clase.

El método del codo es una técnica utilizada para determinar una cantidad adecuada de clusters (K) en K-Means. Consiste en entrenar el modelo con distintos valores de K y calcular la inercia, que mide qué tan cercanos se encuentran los datos a sus centroides.

En este proyecto, el método del codo permitió analizar el comportamiento del modelo al aumentar la cantidad de clusters y apoyar la selección del valor de K . Debido a que no se observó un punto de corte claramente definido, se complementó el análisis utilizando el coeficiente Silhouette para evaluar la calidad de los grupos generados y su separación entre ellos.

Los valores obtenidos mediante el coeficiente Silhouette fueron:

- $K=2 \rightarrow 0.094$
- $K=3 \rightarrow 0.088$
- $K=4 \rightarrow 0.085$
- $K=5 \rightarrow 0.079$
- $K=6 \rightarrow 0.077$
- $K=7 \rightarrow 0.078$

El valor con mejor desempeño correspondió a $K=2$, debido a que presentó el mayor coeficiente Silhouette. Sin embargo, los valores obtenidos continuaron siendo bajos, indicando una baja separación entre los grupos encontrados.

Además, el modelo entrenado y el escalador fueron almacenados utilizando la librería `joblib`, permitiendo reutilizar el modelo sin necesidad de repetir el proceso de entrenamiento y garantizando consistencia en el preprocesamiento de nuevos datos.

f. Conclusiones

El árbol de decisión (profundidad controlada) es útil como herramienta interpretativa: permite identificar las variables que más influyen en las predicciones y generar reglas simples para revisión por expertos agrícolas.

Sin embargo, el desempeño numérico es insuficiente para una solución de producción: accuracy y F1 muestran que `Desecho` no se detecta y `Exportación` se confunde con `Local` con frecuencia.

Las acciones prioritarias para mejorar el sistema son: balanceo de clases (SMOTE o `class\_weight`), optimizar con `f1\_macro`, explorar modelos ensemble y realizar ingeniería de features; además, revisar la calidad y cantidad de etiquetas para las clases minoritarias. A futuro: una pipeline que combine remuestreo dentro de CV, optimización orientada a macro-F1 y evaluación con curvas PR por clase permitirá seleccionar una solución que priorice la detección de `Desecho` si ese es el objetivo crítico del negocio.

El modelo K-Means fue utilizado para identificar agrupaciones dentro del conjunto de datos agrícolas considerando variables relacionadas con el suelo, nutrientes y producción.

Los resultados mostraron que el proceso de escalado influyó en la asignación de registros a los clusters, evidenciando la importancia de normalizar los datos antes del entrenamiento.

La optimización realizada mediante el coeficiente Silhouette determinó que el mejor valor fue $K=2$; sin embargo, el puntaje obtenido fue bajo (≈ 0.094), indicando una separación débil entre los grupos encontrados.

Además, la comparación entre los clusters y la variable `target\_calidad` mostró que las categorías `Desecho`, `Exportación` y `Local` se distribuyen de forma similar entre los grupos, por lo que K-Means no logró representar claramente la clasificación real de los datos.

El modelo entrenado y el escalador fueron almacenados mediante `joblib`, permitiendo reutilizar el modelo sin repetir el proceso de entrenamiento y manteniendo consistencia en el preprocesamiento de nuevos datos.

Aunque el modelo presenta limitaciones frente a modelos supervisados para tareas de clasificación, resultó útil como herramienta de análisis exploratorio, permitiendo identificar patrones generales y comprender mejor el comportamiento del conjunto de datos.